Data Transformation & Visualization with Tidyverse

Data Science Boot Camp Batch 10: Sprint 04 - 05

Author: _gu_npe.tnnx__ , Date: 2024-07-29

เนื้อหา

Library Package	
Tidyverse	3
nycflights23	4
Load Some Data	5
Data Transformation	6
Query Data Best	6
Distance	6
Descriptive of Range Delay	8
Month have most flight	11
Most_Airport	12
Data Visualization	13
Plot Graph 1 : Histogram of month vs. avg_flights	13
Plot Graph 2 : Total Distance by Carrier	14
Plot Graph 3 : Number of Delayed Flights by Airline	15
Plot Graph 4 : Top 10 Airports by Number of Flights	17
Plot Graph 5 : Scatter Plot Diagram of distance	19
Scatter plot month vs. avg_distance	19
Scatter plot month vs. avg_distance vs. carrier	20
Plot Graph 6 : Bar chart of popular destination in 2023	23
Finding the popular destination	23
plotting bar chart of popular destination in 2023	24
Plot Graph 7: bar chart of average arrival delay (minutes) by airline	25
Finding Average of arrival delay for each airline	25
Plot Graph 8 : Percent Delay by Carrier in 2023	27
Create Dataframe to contains delay and percent delay for each carrier	27

Library Package

Tidyverse

```
library(tidyverse)
## — Attaching core tidyverse packages
                                                            tidyverse 2.0.0 ——
## √ dplyr 1.1.4 √ readr
                                      2.1.5
## \checkmark forcats 1.0.0 \checkmark stringr 1.5.1
## \checkmark ggplot2 3.5.0 \checkmark tibble 3.2.1
## √ lubridate 1.9.3 √ tidyr 1.3.1
## √ purrr 1.0.2
## —— Conflicts
— tidyverse conflicts() ——
## X dplyr::filter() masks stats::filter()
## X dplyr::lag() masks stats::lag()
## 1 Use the conflicted package (<a href="http://conflicted.r-lib.org/">http://conflicted.r-lib.org/</a>) to force all conflicts to become
errors
#tinytex::install tinytex(force = TRUE)
```

nycflights23

library(nycflights23)

Inspecting the details about nycflights23 dataset

#?flights

#?airlines

#?airports

#?planes

#?weather



NYCFlights23 คือ ชุดข้อมูลเกี่ยวกับสายการบินต่างๆที่บินมาที่สนามบินในนิวยอร์ค

- flights dataset เป็นข้อมูลเที่ยวบินทั้งหมดในเมืองนิวยอร์คของปี 2013
- airlines dataset เป็นข้อมูลชื่อสายการบินแบ่งตาม carrier code
- airports dataset เป็นข้อมูลที่เกี่ยวกับสนามบิน อาทิเช่น สนามบิน, ตำแหน่งที่ตั้งของสนามบิน
- plans dataset เป็นข้อมูลเกี่ยวกับเครื่องบิน อาทิเช่น ปีที่ผลิตเครื่องบิน, รุ่น (Model) ของเครื่องบิน
- weather dataset เป็นข้อมูลสภาพอากาศรายชั่วโมง

Load Some Data

```
head(flights)
## # A tibble: 6 × 19
    year month day dep_time sched_dep_time dep_delay arr_time sched_arr_time
## <int> <int> <int>
                       <int>
                                   <int>
                                           <dbl> <int>
                                                               <int>
## 1 2023
             1
                 1
                        1
                                2038
                                          203
                                                 328
                                                              3
## 2 2023
                 1
                       18
                                 2300
                                           78
                                                 228
                                                            135
           1
## 3 2023 1
                 1
                       31
                                 2344
                                           47
                                                 500
                                                            426
## 4 2023 1 1
                                                 238
                                                            2352
                       33
                                 2140
                                          173
## 5 2023
                 1
                       36
                                 2048
                                          228
                                                 223
                                                            2252
           1
## 6 2023
            1
                 1
                      503
                                  500
                                           3
                                                808
                                                            815
## # 1 11 more variables: arr delay <dbl>, carrier <chr>, flight <int>,
## # tailnum <chr>, origin <chr>, dest <chr>, air time <dbl>, distance <dbl>,
## # hour <dbl>, minute <dbl>, time hour <dttm>
print(paste("No of data points:", as.character(nrow(flights))))
## [1] "No of data points: 435352"
print(paste("No of columns:", as.character(ncol(flights))))
## [1] "No of columns: 19"
```

จากการสำรวจข้อมูลใน Flight dataset ทำให้รู้ว่ามีข้อมูลที่เก็บในคอลัมน์และแถวทั้งหมด 19
(Column) และ 435352 (Row)
และจากข้อมูลตัวอย่างในส่วนบนและท้ายของข้อมูลทั้งหมดพบว่าเป็นข้อมูลเกี่ยวกับการขึ้นบินและลงจอดของสายการบินต่างๆในแต่ละวัน
 รวมถึงยังมีข้อมูลเกี่ยวกับความล่าช้าของการขึ้นบินและลงจอดของสายการบินแต่ละสายการบินด้วย

Data Transformation

Query Data Best

Distance

```
unique(flights$carrier)
## [1] "UA" "DL" "B6" "AA" "NK" "WN" "AS" "YX" "9E" "HA" "G4" "MQ" "OO" "F9"
length(unique(flights$carrier))
## [1] 14
airlines # Dataframe that contains full name of flights$carrier
## # A tibble: 14 × 2
##
     carrier name
     <chr> <chr>
##
## 1 9E
            Endeavor Air Inc.
## 2 AA
            American Airlines Inc.
## 3 AS
            Alaska Airlines Inc.
## 4 B6
            JetBlue Airways
## 5 DL
            Delta Air Lines Inc.
## 6 F9
            Frontier Airlines Inc.
## 7 G4
            Allegiant Air
## 8 HA
             Hawaiian Airlines Inc.
## 9 MQ
             Envoy Air
## 10 NK
             Spirit Air Lines
## 11 OO
             SkyWest Airlines Inc.
## 12 UA
             United Air Lines Inc.
## 13 WN
              Southwest Airlines Co.
## 14 YX
             Republic Airline
```

```
## Total carrier distance for each
carrier distance <-
  flights %>%
  group_by(carrier) %>%
  summarize(sum distance = sum(distance)) %>%
 select(carrier, sum_distance) %>%
  left_join(airlines, by = "carrier")
carrier distance
## # A tibble: 14 × 3
##
     carrier sum distance name
##
     <chr>
                 <dbl> <chr>
## 19E
              26330226 Endeavor Air Inc.
## 2 AA
              46745602 American Airlines Inc.
## 3 AS
              19458447 Alaska Airlines Inc.
## 4 B6
              75240252 JetBlue Airways
## 5 DL
               78649564 Delta Air Lines Inc.
## 6 F9
               1244713 Frontier Airlines Inc.
## 7 G4
                486266 Allegiant Air
## 8 HA
                1823778 Hawaiian Airlines Inc.
## 9 MQ
                 258879 Envoy Air
## 10 NK
               16468094 Spirit Air Lines
## 11 00
                4042350 SkyWest Airlines Inc.
## 12 UA
               99071109 United Air Lines Inc.
## 13 WN
                12675607 Southwest Airlines Co.
## 14 YX
               43062991 Republic Airline
```

Descriptive of Range Delay

```
des_delay <-
flights %>%

filter(dep_delay > 0) %>%

group_by(carrier) %>%

summarise(count_delay = n(),

avg_delay = mean(dep_delay),

std_delay = sd(dep_delay)) %>%

left_join(airlines) %>%

select(name, count_delay, avg_delay, std_delay) %>%

arrange(desc(count_delay))

## Joining with `by = join_by(carrier)`
```

What is the most number of flights in year 2023?

```
##
    month carrier count
##
    <int> <chr> <int>
## 1
       1 9E
               3985
## 2
       1 AA
               3574
## 3
       1 AS
               542
## 4
       1 B6
               5917
## 5
       1 DL
               4836
## 6
       1 F9
                92
## 7
       1 G4
                 42
## 8
       1 HA
                 31
                  9
## 9
       1 MQ
## 10 1 NK
                1176
## # 1 155 more rows
```

สังเกตว่า ข้อมูลมีเพียง 165 แถวเท่านั้น แต่จาก flights ทั้งหมดมี 14 carrier และ 12 ปี มันควรจะมี 168 แถว หมายความว่ามี 3 แถวที่ไม่มีข้อมูล

```
count_flights %>%
 group_by(month) %>%
 summarise(count = n())
## # A tibble: 12 × 2
##
    month count
##
    <int> <int>
       1
## 1
           14
## 2
       2
           14
## 3
       3
          14
       4
          14
## 4
       5 14
## 5
## 6
       6
          13
## 7
       7
          13
## 8
       8
          13
```

```
## 9 9 14

## 10 10 14

## 11 11 14

## 12 12 14
```

What is the flights that not available?

```
month = c(1:12)
carrier = unique(count_flights$carrier)
# จำนวน flights ที่มีเที่ยวบินทั้งหมด
flights_list <- c(paste(count_flights$month,</pre>
                  count_flights$carrier,
                  sep = "-")
             ) # len = 165
# จำนวน flights ที่เป็นไปได้เอา month x carrier ได้ 168 ข้อมูล
ideal list <- c(paste(rep(month, each = 14),
                 rep(carrier, 12),
                sep = '-')
            ) \# len = 168
answer <- ideal_list[!ideal_list %in% flights list]</pre>
print(capture.output(
 cat(
   "3 Flights which not active in this year is ...\n",
   answer
  )
 ))
```

```
## [1] "3 Flights which not active in this year is ..."

## [2] " 6-MQ 7-MQ 8-MQ"
```

Month have most flight

```
most_flight_month <-
flights %>%
group_by(month) %>%
summarize(avg_total_flight= mean(n())) %>%
arrange(desc(avg_total_flight))
most flight month
## # A tibble: 12 × 2
##
    month avg total flight
##
    <int>
                 <dbl>
## 1
       3
                39514
## 2
       5
                38710
                37476
## 3
       4
                36765
       8
## 4
                 36586
## 5 10
       7
                36211
## 6
                36020
## 7
       1
## 8
       6
                35921
## 9
       9
                35505
## 10
       2
                 34761
## 11
       11
                 34521
## 12
       12
                 33362
```

What is the month that is the most distance?

most_flight_month[1,] # return month and distance

```
## # A tibble: 1 × 2

## month avg_total_flight

## <int> <dbl>
## 1 3 39514
```

Most Airport


```
most flights airport <-
 flights%>%
  group_by(dest)%>%
  summarize(count flights=n(),.groups='drop') %>%
  left join(airports,by= c("dest"="faa")) %>%
  arrange(desc(count flights)) %>%
  slice head(n=10) %>%
  select(dest,name, count flights)
most flights airport
## # A tibble: 10 × 3
##
     dest name
                                                count flights
##
     <chr> <chr>
                                                      <int>
## 1 BOS General Edward Lawrence Logan International Airport
                                                                    19036
## 2 ORD Chicago O'Hare International Airport
                                                             18200
## 3 MCO Orlando International Airport
                                                            17756
## 4 ATL Hartsfield Jackson Atlanta International Airport
                                                               17570
## 5 MIA Miami International Airport
                                                          16076
## 6 LAX Los Angeles International Airport
                                                            15968
## 7 FLL Fort Lauderdale Hollywood International Airport
                                                                 14239
                                                              12866
## 8 CLT Charlotte Douglas International Airport
```

## 9 DFW	Dallas Fort Worth International Airport	11675	
## 10 SFO	San Francisco International Airport	11651	

Data Visualization


Plot Graph 1 : Histogram of month vs. avg_flights

```
ggplot(most_flight_month,
    aes(x=month,y=avg_total_flight)) +
geom_col(fill="blue",
    alpha=0.3,
    color="black") +
geom_text(aes(label=round(avg_total_flight,1))
    ,vjust=-0.3,size=3.5)+
scale_x_continuous(
    breaks= round(unique(most_flight_month$month)))+
theme_minimal()
```



Plot Graph 2: Total Distance by Carrier

```
ggplot(carrier_distance,
    aes(x = reorder(name,-sum_distance),
    y = sum_distance/1000000)) +
geom_col(fill = "orange",
    alpha = 0.3,
    color = "black") +
theme_minimal() +
theme(axis.text.x = element_text(angle = 40, hjust = 1)) +
labs(x = "Carrier",
    y = "Total Distance (x 10^6 km)",
    title = "Total Distance by Carrier")
```




Plot Graph 3: Number of Delayed Flights by Airline

```
delay_flights <-
flights %>%
filter(dep_delay > 0) %>%
group_by(carrier) %>%
summarize(delay_flight = n()) %>%
select(carrier, delay_flight) %>%
arrange(desc(delay_flight)) %>%
left_join(airlines, by = "carrier")
```

PS. You can use des_delay dataframe, but I will create this dataframe ,because i want to practice to create new them.

```
ggplot(delay_flights,
    aes(x = reorder(name,-delay_flight), y = delay_flight)) +
```



Plot Graph 4: Top 10 Airports by Number of Flights

```
avg delay flights <-
  flights %>%
  filter(dep delay > 0) %>%
  group_by(carrier) %>%
  summarize(delay flight = mean(dep delay,na.rm = TRUE)) %>%
  select(carrier, delay flight) %>%
  arrange(desc(delay flight)) %>%
  left_join(airlines, by = "carrier")
ggplot(most_flights_airport,
     aes(x = reorder(dest,-count flights),
        y = count flights)) +
geom_col(fill = "light blue",
       alpha = 0.6,
       color = "black") +
geom_text(aes(label = count flights),
       vjust = -0.3,
       size = 3.5) +
theme_minimal() +
theme(axis.text.x = element text(angle = 40, hjust = 1)) +
labs(x = "Airport Name",
    y = "Number of Flights",
    title = "Top 10 Airports by Number of Flights")
```



Plot Graph 5 : Scatter Plot Diagram of distance


```
set.seed(42)
n <- nrow(flights)
id <- sample(1:n, size = 0.5*n)
train_data <- flights[id,]</pre>
```

Scatter plot month vs. avg_distance

```
df1 <-
train_data %>%
group_by(month) %>%
summarise(avg_distance = mean(distance))


ggplot(data = df1, aes(x = month, y = avg_distance)) +
    geom_point() +
    geom_smooth()

## `geom_smooth()` using method = 'loess' and formula = 'y ~ x'
```




Scatter plot month vs. avg distance vs. carrier

```
##
     <int> <chr> <chr>
                             <dbl>
                                         <dbl>
## 1
        1 9E
                EWR
                            647.
                                      67.2
        1 9E
                JFK
                           491.
                                     47.6
## 2
        1 9E
                LGA
                           478.
                                      50.1
## 3
## 4
        1 AA
               EWR
                           1014.
                                      50.4
## 5
        1 AA
               JFK
                          1583.
                                      43.7
        1 AA
               LGA
                           824.
                                      65.7
## 6
## 7
        1 AS
               EWR
                           2475.
                                      44.4
## 8
        1 AS
               JFK
                          2542.
                                      32.0
## 9
        1 B6
                EWR
                           1268.
                                       38.7
## 10
        1 B6
                JFK
                                      47.5
                           1159.
## # i 327 more rows
ggplot(data = df2, aes(x = month, y = avg_distance, color = avg_dep_delay)) +
 geom_point() +
 facet grid(~ carrier)
```



สังเกตว่าช่วงระทาง 3K เป็นต้นไปค้นพบได้น้อยมาก ซึ่งมีเพียงแค่ Carrier HA เท่านั้นที่เจอ ฉะนั้นจึงเลือกพิจารณากรณีที่ต่ำกว่า 1K และบางเที่ยวบินพอ



Plot Graph 6: Bar chart of popular destination in 2023

Finding the popular destination

```
Pop dest <- flights %>%
         count(dest) %>%
         arrange(-n) %>%
         head(10) %>%
         mutate(
  destination = ifelse(dest=="ATL", "Atlanta (ATL)",
            ifelse(dest=="BQN","Aguadilla (BQN)",
            ifelse(dest=="FLL","Fort Lauderdale (FLL)",
            ifelse(dest=="IAD","Washington (IAD)",
            ifelse(dest=="IAH","Houston (IAH)",
            ifelse(dest=="MCO","Orlando (MCO)",
            ifelse(dest=="MIA", "Miami (MIA)",
            ifelse(dest=="ORD","Chicago (ORD)",
            ifelse(dest=="PBI","West Palm Beach (PBI)",
            ifelse(dest=="TPA","Tampa (TPA)",
            ifelse(dest=="BOS","Boston (BOS)",
            ifelse(dest=="CLT","Charlotte (CLT)",
            ifelse(dest=="DCA","Washington (DCA)",
            ifelse(dest=="LAX","Los Angeles (LAX)",
            ifelse(dest=="SFO","San Francisco (SFO)","NA" ))))))))))
        )
Pop_dest
## # A tibble: 10 × 3
##
     dest
             n destination
## <chr> <int> <chr>
```

```
## 1 BOS 19036 Boston (BOS)

## 2 ORD 18200 Chicago (ORD)

## 3 MCO 17756 Orlando (MCO)

## 4 ATL 17570 Atlanta (ATL)

## 5 MIA 16076 Miami (MIA)

## 6 LAX 15968 Los Angeles (LAX)


## 7 FLL 14239 Fort Lauderdale (FLL)

## 8 CLT 12866 Charlotte (CLT)

## 9 DFW 11675 NA

## 10 SFO 11651 San Francisco (SFO)
```

plotting bar chart of popular destination in 2023



จากกราฟสรุปได้ว่าสถานที่ที่เป็นที่นิยม หรือมีเที่ยวบินลงจอดมากที่สุด 5 อันดับได้แก่ อันดับที่ 1 : Boston อันดับที่ 2 : Chicago อันดับที่ 3 : Orlando อันดับที่ 4 : Atlanta อันดับที่ 5 : Miami

Plot Graph 7: bar chart of average arrival delay (minutes) by airline

ATLBOSCLTDFWFLLLAXMCOMIAORDSFO

Destination

Finding Average of arrival delay for each airline

0

```
df3 <- flights %>%

filter(arr_delay>0)%>%

group_by(carrier) %>%


summarise("Mean_Arr" = mean(arr_delay,na.rm = TRUE)) %>%

left_join(airlines, by = "carrier")
```

Plotting bar chart of average arrival delay (minutes) by airline

```
ggplot(df3, aes(x = Mean_Arr, y =reorder(carrier,Mean_Arr) , fill= name))+
geom_col(size=5,alpha=0.5)+
theme_minimal()+
```

Average Arrival Delay by Carrier name



 จากกราฟด้านบนเป็นกราฟที่แสดงถึง ค่าเฉลี่ย delay time ของแต่ละสายการบิน โดยเฉลี่ยจากระยะเวลาของเที่ยวบินขาเข้าที่ล่าช้าและแยกตามสายการบินด้วย ซึ่งทำให้รู้ว่าสายการบิน F9 มีค่าเฉลี่ย delay time สูงที่สุด ซึ่งคิดเป็นเวลาเฉลี่ย 67.5 นาทีหรือ 1 ชั่วโมงกว่าเลยทีเดียว


Plot Graph 8 : Percent Delay by Carrier in 2023

Create Dataframe to contains delay and percent delay for each carrier

```
df4 <- flights %>%
      filter(!is.na(dep_time)) %>%
      count(carrier) %>%
      rename( "count" = "n")
df4
## # A tibble: 14 × 2
## carrier count
## <chr> <int>
## 1 9E
          52380
## 2 AA
          39940
## 3 AS
          7774
## 4 B6
          64622
## 5 DL
          60616
## 6 F9
          1218
## 7 G4
          667
          364
## 8 HA
           354
## 9 MQ
## 10 NK
          14827
## 11 00
          6214
## 12 UA
           77810
## 13 WN
           12105
## 14 YX
           85723
```

```
df5 <- flights %>%
     filter(dep delay > 0 | arr delay > 0) %>%
     count(carrier) %>%
     rename( "count delay" = "n") %>%
     left join(df4, by = "carrier") %>%
     left join(airlines, by = "carrier") %>%
     mutate(
      percent delay = round((count delay/count)*100,2)
     )
df5
## # A tibble: 14 × 5
     carrier count delay count name
                                                percent_delay
##
                                                    <dbl>
##
     <chr>
                <int> <int> <chr>
## 19E
                17894 52380 Endeavor Air Inc.
                                                       34.2
## 2 AA
                17117 39940 American Airlines Inc.
                                                        42.9
## 3 AS
                3727 7774 Alaska Airlines Inc.
                                                     47.9
## 4 B6
                36434 64622 JetBlue Airways
                                                       56.4
## 5 DL
                28494 60616 Delta Air Lines Inc.
                                                       47.0
## 6 F9
                 825 1218 Frontier Airlines Inc.
                                                     67.7
## 7 G4
                 208 667 Allegiant Air
                                                   31.2
## 8 HA
                                                      75.3
                 274 364 Hawaiian Airlines Inc.
## 9 MQ
                                                    56.2
                  199 354 Envoy Air
                                                     49.7
## 10 NK
                 7369 14827 Spirit Air Lines
## 11 00
                  2941 6214 SkyWest Airlines Inc.
                                                        47.3
                                                        52.4
## 12 UA
                 40767 77810 United Air Lines Inc.
                                                          64.8
## 13 WN
                  7840 12105 Southwest Airlines Co.
## 14 YX
                25765 85723 Republic Airline
                                                       30.1
```

```
#plotting bar chart of percent delay by airline
ggplot(df5,
    aes(x = carrier, y = percent_delay, fill= name))+
geom_col(size = 5,
    alpha = 0.5)+
theme_minimal()+
labs( title = "Percent Delay by Carrier in 2023",
    x = "Carrier",
    y = "Percent Delay" )+
geom_label( aes(label=percent_delay),
    position = position_stack(vjust = 1.05),
    show.legend = FALSE)
```



• จากกราฟด้านบนเป็นกราฟที่แสดงถึง percent flights delay ในแต่ละสายการบิน โดยคิดจากจำนวนเที่ยวบินของแต่ละสายการบินที่เที่ยวบินล่าช้าเทียบกับจำนวนเที่ยวบินทั้งหมดของสาย การบินนั้นๆ ซึ่งพบว่า สายการบินที่มี percent flights delay สูงสุด 3 อันดับ คือ HA, F9 และ WN ตามลำดับ

Thank you :D